

LSTM Autoencoder를 이용한 에스컬레이터 설비 이상 탐지

이종현*, 손정모^o

* (주)이포존 기업부설연구소,

^o (주)이포존 기업부설연구소

e-mail: jh13012@epozen.com*, jmsohn@epozen.com^o

Escalator Anomaly Detection Using LSTM Autoencoder

Jong-Hyeon Lee*, Jung-Mo Sohn^o

*Epozen's research institute,

^oEpozen's research institute

● 요약 ●

에스컬레이터의 고장 여부를 사전에 파악하는 것은 경제적 손실뿐만 아니라 인명 피해를 예방할 수 있어서 매우 중요하다. 실제 이러한 고장 예측을 위한 많은 딥러닝 알고리즘이 연구되고 있지만, 설비의 이상 데이터 확보가 어려워 모델 학습이 어렵다는 문제점이 있다. 본 연구에서는 이러한 문제의 해결 방안으로 비지도 학습 기반의 방법론 중 하나인 LSTM Autoencoder 알고리즘을 사용해 에스컬레이터의 이상을 탐지하는 모델을 생성했고, 최종 실험 결과 모델 성능 AUROC가 0.9966, 테스트 Accuracy가 0.97이라는 높은 정확도를 기록했다.

키워드: 딥러닝(Deep Learning), 에스컬레이터(Escalator), 이상 탐지(Anomaly Detection), LSTM Autoencoder

I. Introduction

한국승강기안전공단에 따르면 21년 3월 기준 국내에 보유한 전체 승강기 개수는 약 75만 개이고, 에스컬레이터는 약 3만 7천 개로 5% 비율을 차지하고 있다. 하지만 승강기 사고 현황을 살펴보면 에스컬레이터가 전체 승강기의 약 57% 정도의 큰 비중을 차지하고 있어 설치 비중에 비해 위험도가 상당히 높은 편이다[1].

특히 지하철과 백화점과 같이 유동인구가 많은 곳의 에스컬레이터의 경우 고장이 발생하게 되면 심각한 인명 피해가 발생하게 되기 때문에, 고장이 발생하기 전 이상 여부를 파악하는 것이 매우 중요하다. 실제로 고장을 사전에 파악하기 위해 점검자가 주기적으로 에스컬레이터를 자체 점검하지만, 점검기준서 없이 점검자의 주관적 판단하에 점검하기 때문에 사실상 형식적인 점검이 되고 있다[2]. 이런 문제를 해결하기 위해 딥러닝을 사용한 이상 탐지 기법이 최근 활발히 연구되고 있다[3][4].

기계의 이상을 탐지하는 기법은 크게 지도학습과 비지도 학습 방법론으로 나뉜다. 지도학습 방법론은 정상 데이터와 이상 데이터를 모두 사용하여 모델을 학습하는 방식으로 비지도 학습보다 정확도가 높은 특징이 있지만, 일반 산업 분야에서는 이상 데이터를 확보하기 어려워서 클래스 불균형(Class-Imbalance) 문제가 자주 발생한다는 문제점이 있다[5].

그에 반해 비지도 학습 방법은 취득되는 대부분 데이터가 정상 데이터라는 가정하에 정상 데이터만을 가지고 모델을 학습을 시키는 방법으로, 학습을 위한 이상 데이터를 확보하지 않아도 된다는 장점과 정상 데이터의 특징을 학습하기 때문에 기존에 알려지지 않은 이상 현상이 발생해도 추가 학습 없이 탐지할 수 있다는 장점 때문에 현재 활발히 연구되고 있다[6][7].

본 연구에서는 이런 비지도 학습 기반의 방법론 중 하나인 LSTM Autoencoder(이하 LSTM AE) 알고리즘에 에스컬레이터 체인의 정상 소음 데이터를 학습시켜 이상 탐지 모델을 생성하고 이에 대한 성능 평가와 결과 분석을 수행하였다.

II. Preliminaries

1. Related works

1.1 LSTM AE 구조 및 특징

LSTM AE 알고리즘은 입력 데이터를 잠재 변수로 압축하는 인코딩 계층과 이를 원본에 가깝게 재구성해내는 디코딩 과정을 거쳐 데이터

의 특징을 추출하는 대표적인 비지도 학습 방법론인 Autoencoder에 시계열 데이터를 학습할 때 사용되는 LSTM 셀을 사용한 방법론으로, LSTM 셀을 적용한 인코더-디코더 구조로 구성된다. 전체적인 LSTM AE의 구조는 아래의 Fig. 1.과 같다[8].

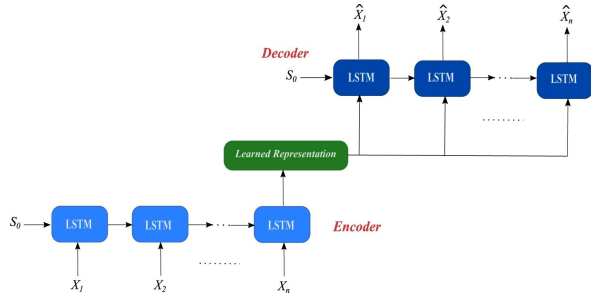


Fig. 1. LSTM Autoencoder Architecture[8]

1.2 이상 탐지 방법

학습된 LSTM AE에 에스컬레이터의 소음 시계열 데이터를 입력하면 입력된 소음 시계열 데이터와 최대한 비슷하게 데이터를 재구성한다. 이때, 재구성한 결과와 원본과의 차이를 의미하는 재구성 손실 값을 설정한 임계값(Threshold)을 비교해서 입력된 데이터가 정상 데이터인지 이상 데이터인지 판단한다.

본 연구에서는 MSE(Mean Squared Error)라는 일반적으로 많이 사용되는 지표를 사용했다[9].




Fig. 2. Process of Anomaly Detection using LSTM AE

III. The Proposed Scheme

1. 모델 학습 수행

1.1 학습 환경

본 연구는 Geforce RTX 2080 GPU 환경에서 수행되었으며, Keras 2.3 버전 기반으로 학습되었다.

연구에 사용된 에스컬레이터 소음 데이터는 인하공업전문대학교의 실험실에 설치된 모형 에스컬레이터의 체인으로 부터 취득되었다. 데이터는 주파수 20Khz로 10분 동안 취득했고, 데이터 세트는 정상 소음과 감속기 기어의 이(Tooth)가 1개 빠진 상태에서 취득한 이상 소음으로 구성되어있다.



Fig. 3. Prototype of Escalator

1.2 데이터 전처리

본 연구에서는 데이터 형태 변환과 z-score 정규화를 통해 데이터를 전처리했다. 원본 데이터는 1,200만 개의 1열짜리 형태로 이루어져 있는데, 1초 동안의 데이터 특징을 사용하기 위해 20,000개씩 600열로 형태를 변경했고, 데이터의 특성을 표준화하기 위해서 Sklearn에서 제공하는 StandardScaler 라이브러리를 적용해서 z-score 정규화를 진행했다.

그리고 2차원 데이터를 LSTM 셀의 입력 데이터 형태로 맞추기 위해 3차원 형태로 변경해서 최종적으로 정상 데이터로만 이루어진 16,000개 훈련 데이터와 이상 데이터가 섞여 있는 2,400개의 검증 데이터, 5,600개의 테스트 데이터를 생성했다.

1.3 모델 구조 및 학습 파라미터

본 연구에서 사용한 LSTM AE 모델은 2개의 인코더 계층과 디코더 계층으로 구성된다. 각 계층 별 은닉층 개수는 아래 Table 1. 과 같다.

Table 1. Number of hidden layers by layer

Layer	Hidden Layers
LSTM Encoder Layer	140
	70
LSTM Decoder Layer	70
	140

모델의 활성화 함수는 Adam, 손실함수는 MSE를 사용했다. 학습 파라미터는 배치사이즈를 32로 설정했고, 과적합(Overfitting)을 피하기 위해 Keras에서 제공하는 EarlyStopping Callback 함수를 사용해 모델의 검증 손실 값이 에포크 5회 이상 감소하지 않는다면 학습을 종료하게 설정했다. 위와 같이 설정하고 학습한 결과 에포크 79회 일 때, 모델의 검증 손실 값이 0.25를 기록했다.




Fig. 4. Model Learning Result

1.4 임계값(Threshold) 설정

본 연구에서는 입력 데이터의 정상 이상 판단 기준이 되는 임계값을 설정하기 위해 정밀도-재현율 그래프를 사용했다. 정밀도-재현율 그래프는 임계값을 변경해가며 정밀도와 재현율을 구해서 그래프로 그리는 데, 그래프에서 정밀도와 재현율이 서로 가장 높게 도출되는 정밀도와 재현율이 교차하는 지점을 모델의 임계값으로 설정했다. Sklearn에서 제공하는 라이브러리를 사용한 결과 Fig. 5와 같이 결과를 도출했다.




Fig. 5. Precision-Recall Curve

2. 모델 성능 평가

본 연구에서는 AUROC 지표를 사용해 모델의 성능을 평가했다. AUROC는 실제 정상 데이터를 이상 데이터로 잘못 예측한 비율 FPR(false positive rate)과 이상 데이터를 이상 데이터로 정확하게 예측한 비율 TPR(true positive rate)을 각각 x축, y축으로 설정한 ROC 곡선의 아래 면적 값을 의미한다[10].

이 AUROC 값이 1에 가까울수록 모델이 우수한 성능을 나타낸다고 볼 수 있는데, Sklearn의 라이브러리를 사용해서 평가를 진행한 결과 Fig. 6과 같이 0.9966이라는 높은 수치의 결과를 기록했다.




Fig. 6. Model Performance Evaluation Using AUROC

3. 테스트

본 연구에서는 Accuracy 지표를 사용해 최종 테스트를 진행했다. Sklearn의 Confusion Matrix 라이브러리를 사용해 Accuracy 값을 도출했고 0.97이라는 높은 정확도를 기록했다.

Fig. 8은 테스트 결과를 시각화 그래프이다. 임계값을 0.49로 설정하고 테스트 데이터를 학습한 모델에 입력한 결과 체인의 정상 소음 데이터(Normal)와 기어 이 빠진 상태에서 취득한 이상 소음 데이터(Break)를 그래프와 같이 분류해내는 것을 확인했다.




Fig. 7. Confusion Matrix




Fig. 8. Visualize Test Results

IV. Conclusions

본 연구는 딥러닝을 사용한 이상 탐지 방법론 중 정상 데이터만 사용하여 학습하는 비지도 학습 기반의 LSTM AE 딥러닝 알고리즘을 사용해 에스컬레이터의 이상을 감지하는 모델을 생성했다.

정밀도-재현율 그래프를 사용해 최적의 임계값을 설정했고, AUROC를 사용해 모델 성능을 평가한 결과 0.9966이라는 높은 수치의 결과를 도출했다. 그리고 최종적으로 테스트 데이터에 대해 Accuracy 지표를 사용해 도출한 결과 0.97이라는 높은 정확도를 기록했다.

이번 연구에서는 결과적으로 높은 정확도로 이상 데이터를 탐지해 냈지만, 사용한 데이터 세트가 현장의 소음이 섞이지 않은 데이터이기 때문에 현장의 소음이 섞인 데이터를 확보 후 추가 연구를 진행할 예정이다.

Systems), 16(6): 1407-1423 <https://doi.org/10.5626/jok.2021.48.1.13>

[10] 이상용. "딥러닝 기반의 설명가능한 다중센서 이상탐지 방법 개발." 국내석사학위논문 명지대학교 대학원, 2020. 서울,

REFERENCES

- [1] B.-S. Kim and P. Park, "에스컬레이터이용자 안전사고예방을 위한 안전관리 방안에 관한 연구," 대한안전경영과학회지, vol. 22, no. 1, pp. 45-50, Mar. 2020. <https://doi.org/10.12812/ksms.2020.22.1.045>
- [2] 이창호, 이창훈, 박상현, 이유진, 김풍일, 최상방. (2019). IoT 기반 에스컬레이터 고장 예지 시스템. 한국컴퓨터정보학회 학술발표논문집, 27(2), 11-12.
- [3] Syed Ibrahim Hassan, Dang Lien Minh, 임수현, 민경복, 남준영, 문현준. (2018). CNN을 이용한 딥러닝 기반 하수관 손상 탐지 분류 시스템. 한국정보통신학회논문지, 22(3), 451-457.
- [4] 김충겸, 강재우. (2017). LSTM기반 반도체 제조 데이터 이상 탐지. 한국정보과학회 학술발표논문집, (), 760-762.
- [5] 김현민. "여러 도메인에 적용할 수 있는 인공지능 기반 다차원 시계열 분석을 통한 이상 탐지 기법 연구." 국내석사학위논문 홍익대학교 대학원, 2021. 서울,
- [6] 김주현, 원정임. (2018). 비지도학습 딥러닝을 활용한 이상거래탐지 시스템 모델. 한국정보과학회 학술발표논문집, (), 917-919.
- [7] 김진영, 조성배. "비지도 적대학습을 이용한 프레임 레벨 비디오 이상탐지 방법." 한국정보과학회 학술발표논문집 (2019): 999-1001.
- [8] Sagheer, A., Kotb, M. Unsupervised Pre-training of a Deep LSTM-based Stacked Autoencoder for Multivariate Time Series Forecasting Problems. Sci Rep 9, 19038 (2019). <https://doi.org/10.1038/s41598-019-55320-6>
- [9] Minji-Seo, Ki-Yong Lee. 2020. A Graph Embedding Technique for Weighted Graphs Based on LSTM Autoencoders. JIPS(Journal of Information Processing